Exposé: Zwischenstand

TabPFN für tabellarische Daten: Grundlagen, Entwicklung und empirischer Vergleich mit baumbasierten Modellen

1 Problemstellung und Motivation

Deep Learning hat große Fortschritte bei Bild-, Sprach- und Audiodaten ermöglicht; bei tabellarischen Daten ist die Leistungsfähigkeit weniger eindeutig. Die Einleitung der Benchmark-Studie beschreibt Tabellendaten als heterogen und verweist auf kleine Stichproben und extreme Werte. Dadurch ist es schwieriger zu bestimmen, welche Veränderungen der Eingaben die Vorhersage unberührt lassen sollten. In den Experimenten untersucht die Studie außerdem unregelmäßige Zielzusammenhänge und unwichtige Merkmale als mögliche Erklärungen für Leistungsunterschiede zwischen neuronalen Netzen und Baumverfahren [2, PDF-S. 1, 6–9].

Der Benchmark umfasst 45 Datensätze. Unter den dort getesteten Modellen schneiden die baumbasierten Verfahren besser ab als die verglichenen neuronalen Netze [2, PDF-S. 1, 3, 6]. Dieser Befund bezieht sich auf die ausgewählten Datensätze, Modelle und Versuchsbedingungen und belegt keine allgemeine Überlegenheit von Baumverfahren. Er begründet jedoch, warum neue Deep-Learning-Ansätze für Tabellendaten anhand transparenter Versuchsbedingungen und geeigneter Baselines eingeordnet werden sollten.

Die TabPFN-Originalarbeit untersucht einen anderen Modellansatz und Versuchsbereich: Ihr zentraler Vergleich umfasst 18 rein numerische OpenML-CC18-Datensätze ohne fehlende Werte und mit höchstens 1.000 Trainingsbeispielen [4, PDF-S. 1, 8]. Die Ergebnisse dieser Arbeit und des 45-Datensatz-Benchmarks lassen sich wegen der unterschiedlichen Modelle, Datensätze und Versuchsbedingungen nicht unmittelbar zu einer gemeinsamen Rangfolge zusammenfassen. Die Arbeit ordnet daher ausgewählte Entwicklungsschritte von TabPFN anhand gemeinsamer Merkmale ein und ergänzt dies um einen transparent abgegrenzten Vergleich mit Baumverfahren auf einer konkreten Aufgabe. Damit wird keine allgemeine Forschungslücke für sämtliche Tabellendaten oder Modellversionen beansprucht.

Das PFN-Grundprinzip besteht darin, ein Modell anhand von Lernaufgaben aus einem vorgegebenen Prior darauf zu trainieren, bayessche Vorhersagen zu approximieren [6, PDF-S. 1–4]. TabPFN verwendet dieses Prinzip für Tabellendaten: Bei einer neuen Aufgabe verarbeitet es gelabelte Beispiele gemeinsam mit den Fällen, für die Vorhersagen benötigt werden, ohne die Modellparameter für diese Aufgabe erneut anzupassen [4, PDF-S. 1–3]. Spätere ausgewählte Modellgenerationen erweitern laut den jeweiligen technischen Berichten den vorgesehenen Anwendungsumfang [3, PDF-S. 1–5][5, PDF-S. 3–5]. Da diese Berichte von den Entwicklerteams stammen, werden ihre Leistungsangaben als berichtete Ergebnisse und nicht als unabhängige Bestätigung eingeordnet. Die Literaturanalyse vergleicht daher nicht nur Architektur und Anwendungsbereich, sondern auch Evaluationsdesign und Quellenstatus. Das eigene Experiment ergänzt diese Einordnung um einen dokumentierten Vergleich auf einer konkreten Aufgabe; es soll keine allgemeine Rangfolge der Modellfamilien begründen, sondern einen nachvollziehbaren, begrenzten Befund liefern.

2 Zielsetzung und Forschungsfragen

Ziel ist, ausgewählte Entwicklungsschritte von TabPFN vor dem Hintergrund der Herausforderungen tabellarischer Daten einzuordnen und eine TabPFN-Version empirisch mit baumbasierten Verfahren zu vergleichen. Die Literaturanalyse ordnet Architektur, Eingabedarstellung, synthetisches Vortraining, Inferenz und Evaluationsbefunde nach gemeinsamen Konzepten. Das Experiment dokumentiert Vorhersageleistung und Laufzeit unter festgelegten Bedingungen.

Aussagekraft und Grenzen beider Teile werden gemeinsam diskutiert.

Übergeordnete Forschungsfrage

Wie adressieren ausgewählte Entwicklungsschritte von TabPFN die Herausforderungen tabellarischer Vorhersageaufgaben, und wie unterscheidet sich eine ausgewählte TabPFN-Version unter festgelegten Versuchsbedingungen von baumbasierten Verfahren hinsichtlich Vorhersageleistung und Laufzeit?

FF1: Literaturteil

Welche methodischen Änderungen beschreiben ausgewählte TabPFN-Arbeiten, welche Herausforderungen tabellarischer Daten sollen sie adressieren, und welche Schlussfolgerungen erlauben die jeweiligen Evaluationen?

FF2: Experimenteller Teil

Wie unterscheiden sich eine ausgewählte TabPFN-Version und ausgewählte baumbasierte Baselines auf einem festgelegten tabellarischen Datensatz hinsichtlich Vorhersageleistung und Laufzeit?

3 Inhaltliche Abgrenzung und roter Faden

Der Literaturteil führt von den Grundlagen des Deep Learning zu den Herausforderungen neuronaler Verfahren auf tabellarischen Daten und zur Rolle baumbasierter Modelle als Vergleich. Darauf folgen die für das Thema notwendigen Grundlagen bayesscher Inferenz, insbesondere Prior und posterior-prädiktive Verteilung. Anschließend werden Foundation Models allgemein und Tabular Foundation Models als spezielle Anwendung eingeordnet. Der Schwerpunkt liegt danach auf Prior-Data Fitted Networks, TabPFN und ausgewählten Schritten seiner Entwicklung.

Die Grundlagen werden auf das für die Forschungsfragen nötige Maß beschränkt. Eine vollständige Übersicht über alle Tabular Foundation Models ist nicht vorgesehen. Ausgangspunkte sind das ursprüngliche TabPFN-Paper sowie die Berichte zu TabPFN-2.5 und TabPFN-3.5. Diese Auswahl ist keine lückenlose Versionsgeschichte; die Recherche soll klären, ob Arbeiten zu TabPFNv2 und TabPFN-3 ergänzt werden müssen.

Der empirische Teil beschränkt sich auf eine ausgewählte TabPFN-Version, einen tabellarischen Datensatz und eine begrenzte Zahl baumbasierter Baselines. German Credit ist ein möglicher Datensatzkandidat; XGBoost und Random Forest sind mögliche Vergleichsverfahren. Datensatz, Aufgabe, Modellversion, Baselines, Metriken und technische Machbarkeit sind noch abzustimmen. Eigenes Foundation-Model-Vortraining, die Entwicklung einer neuen Architektur und kausale Inferenz sind nicht Gegenstand der Arbeit. Ergebnisse des Experiments sollen keine allgemeine Rangfolge der Modellfamilien begründen.

4 Geplantes methodisches Vorgehen

4.1 Literaturanalyse

Der Literaturteil ist vorläufig als deskriptiv-konzeptuelle Literaturanalyse mit konzeptzentrierter Synthese angelegt. Das Reviewdesign wird anhand von Coopers Taxonomie beschrieben, die Reviews unter anderem nach Fokus, Ziel, Perspektive, Abdeckung und Organisation unterscheidet [1]. Die Darstellung orientiert sich an einer konzeptzentrierten statt autorenzentrierten Ordnung, wie sie Webster und Watson für Literaturreviews empfehlen [8, PDF-S. 4]. Verglichen werden gemeinsame Konzepte wie Aufgabenbereich, Architektur, Eingaberepräsentation, synthetischer Prior, Inferenz und Evaluationsdesign.

Die Suche soll Grundlagen zu Deep Learning auf Tabellendaten, bayesscher Inferenz und PFNs sowie Arbeiten zu TabPFN, Tabular Foundation Models, Baumverfahren und Benchmarkmethodik abdecken. Vorgesehen sind Google Scholar, eine ergänzende Metadaten- oder Zitationssuche, offizielle Publikationsseiten und arXiv. Englische Suchbegriffe werden kombiniert, auf den jeweiligen Plattformen getestet und angepasst. Rückwärts- und Vorwärtssuchen ergänzen die Datenbanksuche.

Ein- und Ausschlusskriterien werden vor dem Screening festgelegt. Nach Dublettenbereinigung erfolgen Titel- und Abstractprüfung sowie Volltextprüfung. Peer-reviewte Arbeiten, Preprints und technische Berichte können einbezogen werden; Publikationsstatus und Unabhängigkeit werden getrennt ausgewiesen. Suchdatum, Plattform, vollständige Suchanfragen, Einschränkungen, Trefferzahlen und Volltextausschlüsse mit Gründen werden dokumentiert. Eine Teilmenge soll nach zeitlichem Abstand erneut anhand derselben Kriterien geprüft werden.

Die ausgewählten Beiträge sollen in einer Konzeptmatrix unter anderem nach Aufgabenbereich, Architektur und Eingabereprăsentation, synthetischem Prior, Vorverarbeitung und Inferenz, Evaluationsdesign, Baselines und Grenzen verglichen werden. Die Synthese soll Übereinstimmungen, Unterschiede und Entwicklungslinien herausarbeiten. Nicht vergleichbare Benchmarks werden nicht zu einer gemeinsamen Rangfolge zusammengefasst.

Die Recherche ist noch nicht abgeschlossen. Deshalb enthält dieser Zwischenstand keine Trefferzahlen oder Auswahlresultate. PRISMA 2020 formuliert Berichtsleitlinien für systematische Reviews [7, PDF-S. 1]. Die geplante Literaturanalyse wird nicht als vollständig PRISMA-konformes systematisches Review ausgewiesen. Ein Flussdiagramm wird nur erstellt, wenn der tatsächlich durchgeführte Auswahlprozess dafür dokumentiert ist und die entsprechenden Zahlen vorliegen.

4.2 Experimenteller Vergleich

Geplant ist der Vergleich einer TabPFN-Version mit baumbasierten Verfahren auf einem öffentlichen Datensatz. German Credit ist ein noch zu prüfender Kandidat; XGBoost und Random Forest sind mögliche Baselines. Vorhersageleistung und Laufzeit werden getrennt ausgewertet und dokumentiert. Die endgültige Festlegung steht aus.

5 Vorläufige Gliederung

1. Einleitung: Motivation, Problemstellung, Ziel und Forschungsfragen
2. Grundlagen: Deep Learning auf Tabellendaten, baumbasierte Verfahren, bayessche Inferenz und Foundation Models
3. Methodik der Literaturanalyse
4. Entwicklung von TabPFN: Grundlagen, ausgewählte Versionen und konzeptzentrierter Vergleich
5. Experimenteller Vergleich: Datensatz, Modelle und Evaluationsdesign
6. Ergebnisse des Experiments
7. Diskussion: gemeinsame Einordnung, Aussagekraft und Grenzen
8. Fazit und Ausblick

Literatur

[1] Harris M. Cooper. Organizing knowledge syntheses: A taxonomy of literature reviews. *Knowledge in Society*, 1(1):104–126, 1988.

[2] Leo Grinsztajn, Edouard Oyallon, and Gael Varoquaux. Why do tree-based models still outperform deep learning on typical tabular data? In *Advances in Neural Information Processing Systems*, volume 35, pages 507–520. Curran Associates, Inc., 2022.

[3] Léo Grinsztajn, Klemens Flöge, Oscar Key, Felix Birkel, Philipp Jund, Brendan Roof, Benjamin Jäger, Dominik Safaric, Simone Alessi, Adrian Hayler, Mihir Manium, Rosen Yu, Felix Jablonski, Shi Bin Hoo, Anurag Garg, Jake Robertson, Magnus Bühler, Vladyslav Moroshan, Lennart Purucker, Clara Cornu, Lilly Charlotte Wehrhahn, Alessandro Bonetto, Bernhard Schölkopf, Sauraj Gambhir, Noah Hollmann, and Frank Hutter. TabPFN-2.5: Advancing the State of the Art in Tabular Foundation Models, February 2026. arXiv:2511.08667 [cs.LG].

[4] Noah Hollmann, Samuel Müller, Katharina Eggensperger, and Frank Hutter. TabPFN: A Transformer That Solves Small Tabular Classification Problems in a Second, September 2023. arXiv:2207.01848 [cs.LG].

[5] Benjamin Jäger, Nick Erickson, Léo Grinsztajn, Felix Birkel, Klemens Flöge, Oscar Key, Kürşat Kaya, Jonas Kübler, Adèle Frankel, Tobias Schröder, Anurag Garg, Jan Hendrik Metzen, David Salinas, Simon Bing, Kristina Collins, Tuana Çelik, Vahid Balazadeh, Lydia Sidhoum, Tomás Pereda, Brendan Roof, Andrej Tschalzev, Siyuan Guo, Philipp Singer, Lennart Purucker, Jake Robertson, Marie Salmon, Philipp Jund, Jerry Chen, Diana Kriuchkova, Arthur Cahu, Eliott Kalfon, Adrian Hayler, Georg Grab, Vitor Monteiro, Lilly Wehrhahn, Dominik Safaric, Clara Cornu, Alan Arazi, Rylee Grace, Simone Alessi, Mihir Manium, Bernhard Schölkopf, Yann LeCun, Madelon Hulsebos, Sauraj Gambhir, Noah Hollmann, and Frank Hutter. TabPFN-3.5: Technical Report, September 2026. arXiv:2609.17895 [cs.LG].

[6] Samuel Müller, Noah Hollmann, Sebastian Pineda Arango, Josif Grabocka, and Frank Hutter. Transformers Can Do Bayesian Inference, August 2024. arXiv:2112.10510 [cs.LG].

[7] Matthew J. Page, Joanne E. McKenzie, Patrick M. Bossuyt, Isabelle Boutron, Tammy C. Hoffmann, Cynthia D. Mulrow, Larissa Shamseer, Jennifer M. Tetzlaff, Elie A. Akl, Sue E. Brennan, Roger Chou, Julie Glanville, Jeremy M. Grimshaw, Asbjørn Hróbjartsson, Manoj M. Lalu, Tianjing Li, Elizabeth W. Loder, Evan Mayo-Wilson, Steve McDonald, Luke A. McGuinness, Lesley A. Stewart, James Thomas, Andrea C. Tricco, Vivian A. Welch, Penny Whiting, and David Moher. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, 372:n71, 2021.

[8] Jane Webster and Richard T. Watson. Analyzing the past to prepare for the future: Writing a literature review. *MIS Quarterly*, 26(2):xiii–xxiii, 2002.