Exposé zur Bachelorarbeit

Robustheit von TabPFN-3.5 gegenüber irrelevanten Merkmalen: Eine kontrollierte Untersuchung im Vergleich zu LightGBM

Vorläufiger Entwurf

1 Problemstellung und Motivation

Tabellarische Klassifikationsaufgaben unterscheiden sich in Umfang, Merkmalstypen, Klassenverteilung und Datenqualität. Für solche Aufgaben werden häufig baumbasierte Verfahren eingesetzt. Grinsztajn et al. untersuchen in einem Benchmark mit 45 kuratierten Datensätzen verschiedene baumbasierte und neuronale Verfahren. Sie berichten unter anderem, dass das Hinzufügen unkorrelierter irrelevanter Merkmale die Leistung der untersuchten neuronalen Modelle beeinträchtigen und den Abstand zu den Baumverfahren vergrößern kann [1]. Der Befund gilt für die in dieser Studie getesteten Modelle und Versuchsbedingungen, nicht automatisch für jede neuronale Architektur oder jede spätere Modellgeneration.

TabPFN verfolgt einen anderen Ansatz als ein pro Datensatz neu trainiertes neuronales Netz: Ein Transformer wird vorab auf synthetisch erzeugten Klassifikationsaufgaben trainiert und verarbeitet beim Einsatz die beschrifteten Trainingsbeispiele als Kontext. Das ursprüngliche Paper evaluiert TabPFN vor allem auf kleinen Klassifikationsdatensätzen und untersucht zusätzlich den Einfluss uninformativer Merkmale. Für die damalige Modellversion berichten die Autoren eine geringere Robustheit gegenüber solchen Merkmalen als bei LightGBM [2]. Dieser Befund bietet einen konkreten Ausgangspunkt für die vorliegende Arbeit.

Der technische Bericht zu TabPFN-3.5 beschreibt unter anderem Anpassungen des synthetischen Priors für Datensätze mit größeren Merkmalszahlen und berichtet Benchmark-Ergebnisse für hochdimensionale Daten [3]. Der Bericht ist eine Evaluation des Modellentwicklerteams und wird in der Arbeit entsprechend als solcher eingeordnet. Eine größere unterstützte Merkmalszahl beantwortet für sich genommen nicht, wie empfindlich TabPFN-3.5 reagiert, wenn gezielt zusätzliche Merkmale ohne Zusammenhang mit dem Ziel eingeführt werden. Im geprüften Bericht wird kein isoliertes Experiment mit kontrolliert hinzugefügten unabhängigen Störmerkmalen berichtet. Ob neuere unabhängige oder anwendungsbezogene Studien diese konkrete Frage bereits untersuchen, wird vor einer abschließenden Behauptung einer Forschungslücke systematisch nachgeprüft.

Damit ergibt sich eine klar begrenzte praktische Frage: Verhält sich TabPFN-3.5 bei kontrollierter Zugabe irrelevanter Merkmale anders als LightGBM, und verändert sich die Vorhersageleistung der Modelle mit zunehmendem Störmerkmal-Anteil? Die Untersuchung soll keinen allgemeinen Sieger zwischen Foundation Models und Baumverfahren bestimmen. Sie isoliert stattdessen einen Datenfaktor, der in früheren Arbeiten als relevant beschrieben wurde.

2 Zielsetzung und möglicher Beitrag

Ziel der Arbeit ist es, ausgewählte methodische Änderungen von TabPFN bis Version 3.5 und die Aussagekraft relevanter Evaluationen knapp und kritisch einzuordnen. Darauf aufbauend wird in einem kontrollierten Klassifikationsexperiment untersucht, wie sich die Leistung von TabPFN-3.5 und LightGBM verändert, wenn unabhängig erzeugte irrelevante Merkmale schrittweise zu den Eingabedaten hinzugefügt werden.

Der praktische Beitrag besteht in einer reproduzierbaren Untersuchung mit mehreren geeigneten Datensätzen, festgelegten Störmerkmal-Stufen, wiederholten Datenaufteilungen und einer klar benannten Baum-Baseline. Gemessen wird die Veränderung gegenüber der jeweiligen Bedingung ohne zusätzliche Störmerkmale. Dadurch steht die Empfindlichkeit gegenüber dem kontrollierten Eingriff im Vordergrund und nicht allein ein Rangvergleich der Modelle auf unterschiedlichen Datensätzen. Die Arbeit entwickelt keinen neuen Algorithmus und beansprucht nicht, Ergebnisse für alle baumbasierten Verfahren zu liefern. Ob die Untersuchung eine Forschungslücke schließt, hängt vom noch ausstehenden Abgleich mit der neueren Literatur ab; bis dahin wird sie als empirische Prüfung und mögliche Erweiterung früherer Befunde bezeichnet.

3 Forschungsfragen

Übergeordnete Forschungsfrage

Wie robust ist TabPFN-3.5 gegenüber schrittweise hinzugefügten unabhängigen, irrelevanten Merkmalen im Vergleich zu LightGBM, und wie ist dieses Ergebnis anhand der methodischen Entwicklung und bisherigen Evaluationen von TabPFN einzuordnen?

Die übergeordnete Frage verbindet Literatur- und Experimentteil. Die Literaturanalyse klärt, wie das Modell und die Fragestellung einzuordnen sind; der experimentelle Teil beantwortet den konkreten Leistungsvergleich. Die übergeordnete Frage verspricht keine experimentelle Prüfung sämtlicher TabPFN-Entwicklungsschritte.

FF1: Literaturanalyse

Welche relevanten methodischen Änderungen und adressierten Herausforderungen tabellarischer Daten beschreiben ausgewählte TabPFN-Arbeiten, und welche Schlussfolgerungen erlauben ihre Evaluationen?

FF2: Experimenteller Vergleich

Wie verändert sich die Klassifikationsleistung von TabPFN-3.5 und LightGBM bei schrittweiser Zugabe unabhängiger, irrelevanter Merkmale?

FF2 wird anhand der Veränderung der vorab festgelegten Leistungsmetriken über Störmerkmal-Stufen, Datensätze und Wiederholungen beantwortet. Aus dem Vergleich mit LightGBM werden keine Aussagen über andere Baumverfahren abgeleitet.

4 Inhaltliche Abgrenzung

Die Untersuchung konzentriert sich auf überwachte tabellarische Klassifikation und auf den Einfluss künstlich hinzugefügter Merkmale, die unabhängig von den ursprünglichen Eingaben und der Zielvariable erzeugt werden. Der Modellvergleich umfasst TabPFN-3.5 und LightGBM. Die genaue Version, Paketkonfiguration und Verfügbarkeit von TabPFN-3.5 werden vor Beginn des Hauptversuchs technisch und lizenzrechtlich geprüft.

Nicht Gegenstand der Arbeit sind Explainable AI, SHAP oder LIME, Kausalaussagen, Regression, ein umfassender Benchmark vieler Modellfamilien oder eine vollständige Versionsgeschichte von TabPFN. Laufzeit wird nicht als zentrale Forschungsfrage behandelt; eine ergänzende Laufzeitmessung kann nur aufgenommen werden, wenn sie unter dokumentierten und fairen Bedingungen realisierbar ist. Vorgängermodelle werden ausschließlich dort herangezogen, wo sie für die Einordnung der aktuellen Version und früherer Robustheitsbefunde nötig sind.

5 Roter Faden und inhaltlicher Aufbau

Der rote Faden führt vom Problem zu einer gezielten empirischen Prüfung:

> Tabellarische Daten enthalten Merkmale mit unterschiedlichem Informationswert $\longrightarrow$ frühere Benchmarks und TabPFN-Arbeiten berichten einen Einfluss irrelevanter Merkmale auf die Leistung bestimmter Modelle $\longrightarrow$ TabPFN-3.5 erweitert laut technischem Bericht den Umgang mit größeren Merkmalszahlen, doch daraus folgt nicht automatisch Robustheit gegenüber gezielt hinzugefügten Störmerkmalen $\longrightarrow$ die Arbeit variiert diese Merkmale kontrolliert und vergleicht die Veränderung der Klassifikationsleistung von TabPFN-3.5 und LightGBM.

Grundlagen zu tabellarischem Deep Learning, Prior-Data Fitted Networks und dem synthetischen Prior von TabPFN dienen dazu, die Modellidee und den Bezug der Forschungsfrage zu erklären. Sie werden nicht zu einem breiten allgemeinen Abriss über KI oder LLMs ausgebaut. Die Entwicklung früherer Versionen ist selektiver Kontext statt eines eigenen Kapitels zur Versionsgeschichte. Der Schwerpunkt und die Eigenleistung liegen im kontrollierten Experiment und dessen kritischer Auswertung.

6 Vorgehen der Literaturanalyse

Die Literaturanalyse wird als fokussierte, nachvollziehbare Recherche angelegt, nicht als Anspruch auf ein vollständiges systematisches Review aller Tabular Foundation Models. Im Zentrum stehen:

- das ursprüngliche TabPFN-Paper und die darin berichteten Evaluationen, insbesondere der Befund zu uninformativen Merkmalen;
- der Benchmark von Grinsztajn et al. als Kontext für den Vergleich neuronaler Modelle und Baumverfahren;
- der TabPFN-3.5-Bericht mit Fokus auf die für Feature-Zahl, synthetischen Prior und Evaluation relevanten Aussagen;
- neuere Arbeiten, die gezielt TabPFN-3/3.5, irrelevante Merkmale, Feature-Robustheit oder kontrollierte Feature-Interventionen untersuchen.

Gesucht wird unter anderem in Google Scholar, arXiv und den Literaturverzeichnissen einschlägiger Konferenzbeiträge. Vorläufige Suchkombinationen kombinieren `TabPFN` mit `irrelevant features`, `robustness`, `noise features` oder `feature selection`; zusätzlich wird nach `tabular foundation model` zusammen mit `robustness` und `irrelevant features` gesucht. Suchdatum, Suchanfragen, relevante Treffer und Ausschlüsse werden festgehalten. Bei der Synthese werden Modellversion, Datensatz, Versuchsaufbau, Metriken und Grenzen der jeweiligen Quelle gegenübergestellt. Entwicklerberichte werden als solche kenntlich gemacht; berichtete Benchmarkresultate werden nicht ungeprüft als unabhängige Evidenz interpretiert.

7 Vorläufiger experimenteller Vergleich

Datensätze und Versuchsbedingungen

Vorgesehen sind zunächst etwa vier öffentlich verfügbare numerische Klassifikationsdatensätze. Die Beschränkung auf numerische Eingaben soll zusätzliche Effekte aus unterschiedlichen Verfahren zur Kodierung kategorialer Merkmale vermeiden. Die Datensätze werden anhand vorab festgelegter Kriterien ausgewählt: Eignung für TabPFN-3.5, Anzahl der Beobachtungen und Merkmale, Klassenverteilung, Datenqualität und verfügbare Nutzungsrechte. Die Datensatzauswahl und Ausschlüsse werden dokumentiert. Das genaue Set wird erst nach technischer Prüfung festgeschrieben.

Für jeden Datensatz werden identische, stratifizierte Datenaufteilungen für beide Modelle verwendet. Auf die Eingabemerkmale werden in kontrollierten Stufen zusätzliche numerische Störmerkmale gelegt, die unabhängig von den ursprünglichen Merkmalen, voneinander und der Zielvariable erzeugt werden. Als erste Versuchsplanung sind unabhängige standardnormalverteilte Störmerkmale und Stufen von 0, 0,5, 1 und 2 zusätzlichen Merkmalen pro ursprünglicher Eingabespalte vorgesehen; nicht-ganzzahlige Stufenzahlen werden auf ganze Spalten gerundet. Die genaue Definition der ursprünglichen Eingabespalten und die Machbarkeit der höchsten Stufe werden im Pilotlauf geprüft. Dieselben erzeugten Merkmale, Seeds und Splits werden für beide Modelle verwendet.

Die Auswertung wird über mehrere wiederholte Seeds durchgeführt. Eine unveränderte Bedingung ohne zusätzliche Merkmale dient pro Datensatz und Modell als Referenz. Die experimentellen Bedingungen unterscheiden sich innerhalb eines Vergleichs nur durch die Zahl der Störmerkmale.

Modelle, Metriken und Auswertung

TabPFN-3.5 wird mit dokumentierter Paket- und Modellversion sowie festgehaltenen Inferenzoptionen ausgewertet. LightGBM wird als einzelnes baumbasiertes Gradient-Boosting-Modell eingesetzt [4]. Um Robustheit statt zusätzlicher Tuningeffekte zu vergleichen, werden Modellkonfigurationen vor der Auswertung der Störmerkmal-Stufen festgelegt. Für LightGBM kann die Konfiguration auf einer Validierung der unveränderten Trainingsdaten bestimmt und anschließend über alle Stufen eingefroren werden; TabPFN wird mit seiner dokumentierten Standardkonfiguration verwendet. Diese asymmetrische Trainingsweise wird als Teil des Designs offengelegt: Verglichen wird die Veränderung unter demselben Eingriff, nicht der Aufwand einer gleich großen Hyperparametersuche.

Als primäre Kennzahl ist zunächst Balanced Accuracy vorgesehen, um Klassifikationsleistung über Datensätze mit unterschiedlichen Klassenverteilungen vergleichbar aus-

zuwerten. Log-Loss kann ergänzend berichtet werden, sofern die Wahrscheinlichkeitsausgaben technisch vergleichbar und ohne zusätzliche, unterschiedlich abgestimmte Kalibrierung auswertbar sind. Für jedes Modell und jeden Datensatz wird insbesondere die Änderung gegenüber der Bedingung ohne Störmerkmale dargestellt. Ergebnisse pro Datensatz, Streuung über Wiederholungen und aggregierte Ergebnisse werden getrennt ausgewiesen. Unsicherheit wird angemessen berichtet; eine aggregierte Rangliste allein ist nicht ausreichend.

Machbarkeit und Grenzen

Vor dem Hauptversuch wird ein Pilot mit mindestens einem Datensatz durchgeführt. Er prüft Installation und Lizenzbedingungen von TabPFN-3.5, Laufzeit, Speicherbedarf, Datenformat und die geplante Vorverarbeitung. Datensätze, Störmerkmal-Stufen und Wiederholungszahlen werden nur dann festgelegt, wenn sie mit der verfügbaren Hardware realisierbar sind.

Unabhängig generierte Merkmale sind in endlichen Stichproben nicht zwingend empirisch unkorreliert. Wiederholte Seeds und die kontrollierte Erzeugungsprozedur helfen, zufällige Stichprobeneffekte sichtbar zu machen, beseitigen sie aber nicht vollständig. Die Resultate gelten außerdem für die ausgewählten Datensätze, die festgelegte Datenpipeline und genau die beiden untersuchten Modelle. Sie erlauben keine direkte Verallgemeinerung auf alle Datendomänen oder alle baumbasierten Verfahren.

8 Vorläufige Gliederung

1. **Einleitung:** Problemstellung, Motivation, Zielsetzung, Forschungsfragen, Abgrenzung und Aufbau.
2. **Grundlagen:** Tabellarische Klassifikation; TabPFN und Prior-Data Fitted Networks; synthetische Priors; Gradient Boosting und LightGBM; irrelevante Merkmale und Robustheitsbegriffe.
3. **Stand der Forschung und Literaturanalyse:** Ausgewählte methodische Änderungen bis TabPFN-3.5; Benchmarkbefunde und deren Grenzen; frühere Experimente mit irrelevanten Merkmalen; Herleitung des Untersuchungsbedarfs.
4. **Methodik:** Forschungsdesign; Datensatzauswahl; Störmerkmal-Erzeugung; Modelle und Konfigurationen; Splits, Wiederholungen, Metriken und Auswertung.
5. **Ergebnisse:** Ergebnisse ohne Störmerkmale; Leistungsänderung mit zunehmender Störmerkmal-Zahl; Vergleich zwischen Modellen und Datensätzen.
6. **Diskussion:** Beantwortung der Forschungsfragen; Einordnung in die Literatur; Bedeutung und Limitationen.
7. **Fazit und Ausblick.**

Literatur

[1] Leo Grinsztajn, Edouard Oyallon, and Gael Varoquaux. Why do tree-based models still outperform deep learning on typical tabular data? In *Advances in Neural Information Processing Systems*, volume 35, pages 507–520. Curran Associates, Inc., 2022.

[2] Noah Hollmann, Samuel Müller, Katharina Eggensperger, and Frank Hutter. TabPFN: A Transformer That Solves Small Tabular Classification Problems in a Second, September 2023. arXiv:2207.01848 [cs.LG].

[3] Benjamin Jäger, Nick Erickson, Léo Grinsztajn, Felix Birkel, Klemens Flöge, Oscar Key, Kürşat Kaya, Jonas Kübler, Adèle Frankel, Tobias Schröder, Anurag Garg, Jan Hendrik Metzen, David Salinas, Simon Bing, Kristina Collins, Tuana Çelik, Vahid Balazadeh, Lydia Sidhoum, Tomás Pereda, Brendan Roof, Andrej Tschalzev, Siyuan Guo, Philipp Singer, Lennart Purucker, Jake Robertson, Marie Salmon, Philipp Jund, Jerry Chen, Diana Kriuchkova, Arthur Cahu, Eliott Kalfon, Adrian Hayler, Georg Grab, Vitor Monteiro, Lilly Wehrhahn, Dominik Safaric, Clara Cornu, Alan Arazi, Rylee Grace, Simone Alessi, Mihir Manium, Bernhard Schölkopf, Yann LeCun, Madelon Hulsebos, Sauraj Gambhir, Noah Hollmann, and Frank Hutter. TabPFN-3.5: Technical Report, September 2026. arXiv:2609.17895 [cs.LG].

[4] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154, 2017.