BACHELORARBEIT · KONZEPT

Thema und Forschungsfrage

VORLÄUFIGER ARBEITSTITEL

TabPFN for Tabular Data: Development and Empirical Comparison with Tree-Based Models

TabPFN für tabellarische Daten: Entwicklung und empirischer Vergleich mit baumbasierten Modellen

Die Arbeit verbindet eine Literaturübersicht zur Entwicklung von TabPFN mit einem eigenen empirischen Vergleich. Der Titel wird angepasst, falls sich Umfang oder Vergleichsmodelle im Gespräch mit dem Betreuer ändern.

Forschungsfrage

Wie wurde TabPFN weiterentwickelt, um Herausforderungen tabellarischer Daten zu adressieren, und wie schneidet eine ausgewählte TabPFN-Version im Vergleich zu baumbasierten Verfahren bei einer konkreten tabellarischen Vorhersageaufgabe ab?

Unterfragen

1. Welche Eigenschaften tabellarischer Daten erschweren den Einsatz von Deep Learning, und warum sind baumbasierte Verfahren auf solchen Daten starke Vergleichsmodelle?
2. Welche methodischen Änderungen zeigen sich zwischen dem ursprünglichen TabPFN-Paper, TabPFN-2.5 und TabPFN-3.5, insbesondere bei Architektur, Eingaberepräsentation und synthetischem Vortraining?
3. Wie unterscheiden sich TabPFN und ausgewählte baumbasierte Modelle auf einem festgelegten Datensatz hinsichtlich Vorhersageleistung und Rechenaufwand?
4. Welche Einschränkungen folgen aus Datensatzwahl, Evaluation, Modellversion, Hardware und Lizenzierung?

Roter Faden

Herausforderung
Schwierigkeiten tabellarischer Daten und Stärke baumbasierter Baselines.

Ansatz und Entwicklung
PFN-Grundidee, In-Context Learning und ausgewählte TabPFN-Meilensteine.

Überprüfung und Einordnung
Eigener Modellvergleich; Aussagekraft, Einsatzgrenzen und offene Fragen.

GLIEDERUNG · TEIL I

Grundlagen und Modellentwicklung

1 Einleitung

1.1 Motivation: Bedeutung tabellarischer Daten in praktischen Anwendungen
1.2 Problemstellung: Herausforderungen für Deep Learning auf Tabellendaten
1.3 Ziel und Abgrenzung der Arbeit
1.4 Forschungsfrage und Unterfragen
1.5 Aufbau der Arbeit

2 Hintergrund

2.1 Tabellarische Daten: Struktur, Merkmale und typische Herausforderungen
2.2 Deep Learning auf Tabellendaten und Unterschiede zu Bild- und Sprachdaten
2.3 Baumbasierte Verfahren als wichtige Baselines
2.4 Tabular Foundation Models und In-Context Learning
2.5 Prior-Data Fitted Networks und bayessche Interpretation

3 Vorgehen der Literaturübersicht

3.1 Ziel und Umfang der Literaturauswahl
3.2 Verwendete Suchquellen und Suchbegriffe
3.3 Kriterien für Ein- und Ausschluss von Arbeiten
3.4 Vorgehen beim strukturierten Vergleich der ausgewählten Arbeiten

4 Entwicklung von TabPFN

4.1 Ursprüngliches TabPFN: Grundidee und erste Umsetzung
4.2 TabPFN-2.5: Erweiterungen und adressierte Grenzen
4.3 TabPFN-3.5: weitere Änderungen und neue Fähigkeiten
4.4 Vergleich über gemeinsame Aspekte
4.5 Zwischenfazit: Welche Probleme wurden adressiert, welche bleiben offen?

GLIEDERUNG · TEIL II

Experiment und Einordnung

5 Experimenteller Vergleich

5.1 Ziel des Experiments und Bezug zur Forschungsfrage
5.2 Datensatz und Vorhersageaufgabe
5.3 Datenbereinigung und Vorverarbeitung
5.4 Verglichene Modelle: ausgewählte TabPFN-Version und baumbasierte Baselines
5.5 Versuchsaufbau: Splits, Validierung und Umgang mit Zufälligkeit
5.6 Metriken für Vorhersageleistung
5.7 Messung von Laufzeit und gegebenenfalls Ressourcenverbrauch
5.8 Implementierung und Reproduzierbarkeit

6 Ergebnisse

6.1 Ergebnisse zur Vorhersageleistung
6.2 Ergebnisse zu Laufzeit und Ressourcen
6.3 Vergleich der Modelle und Beobachtungen

7 Diskussion

7.1 Beantwortung der Forschungsfrage anhand von Literatur und Experiment
7.2 Einordnung der eigenen Ergebnisse im Vergleich zur Literatur
7.3 Einfluss von Datensatz, Metrik, Split und Modellkonfiguration
7.4 Grenzen der Untersuchung und mögliche Verzerrungen
7.5 Praktische Aspekte: Skalierung, Verfügbarkeit und Lizenzierung

8 Fazit und Ausblick

8.1 Zusammenfassung der wichtigsten Erkenntnisse
8.2 Abschließende Beantwortung der Forschungsfrage
8.3 Ausblick auf weiterführende Untersuchungen

BESPRECHUNG

Planungshinweise und offene Entscheidungen

Literaturbasis und Abgrenzung

Die bisherigen TabPFN-Arbeiten behandeln das ursprüngliche TabPFN, TabPFN-2.5 und TabPFN-3.5. Sie sind ausgewählte Meilensteine, *keine lückenlose Versionsgeschichte* und nicht schlicht „Version 1, 2 und 3“. Ob weitere Berichte zu TabPFN-v2 oder TabPFN-3 aufgenommen werden, ist noch abzuklären.

Transformers Can Do Bayesian Inference liefert den PFN-Hintergrund. Die Arbeit *Why do tree-based models still outperform deep learning on typical tabular data?* motiviert die Herausforderungen und die Rolle baumbasierter Verfahren. Beide gehören vor allem in das Grundlagenkapitel.

Vergleichsrahmen für den Literaturteil

Die Modellversionen werden anhand derselben Aspekte verglichen: Aufgaben und Datensatzgrößen; Architektur und Eingabekodierung; synthetischer Prior und Trainingsaufgaben; Vorverarbeitung und Inferenz; Benchmarks und Vergleichsmodelle; Einschränkungen und Verfügbarkeit. Herstellerberichte und von den Autoren berichtete Resultate sind als solche zu kennzeichnen.

Noch nicht festgelegter Praxisteil

Offen sind Datensatz, Klassifikation oder Regression, TabPFN-Version, Baselines, Metriken und Hardware. XGBoost und Random Forest sind mögliche Vergleichsmodelle. Die Auswahl erfolgt nach Rücksprache mit dem Betreuer und abhängig von Daten, Umfang und verfügbarer Implementierung.

Fragen für das Betreuungsgespräch

1. Ist die geplante Kombination aus Literaturübersicht und eigenem empirischem Vergleich für die Bachelorarbeit passend?
2. Gibt es einen vom Betreuer empfohlenen Datensatz oder eine konkrete Anwendungsaufgabe? Falls nicht: Welche Anforderungen soll ein selbst ausgewählter öffentlicher Datensatz erfüllen?
3. Soll die experimentelle Aufgabe Klassifikation oder Regression sein?
4. Welche TabPFN-Version ist für die Implementierung und den vorgesehenen Einsatzzweck verfügbar und lizenzrechtlich geeignet?
5. Sind XGBoost und Random Forest als Vergleich ausreichend, oder wird eine weitere Baseline erwartet?
6. Soll die Versionsgeschichte über die drei ausgewählten Meilensteine hinaus erweitert werden, insbesondere um TabPFN-v2 und TabPFN-3?
7. Welche Anforderungen gelten an Suchstrategie, Umfang und Formalisierung der Literaturübersicht?
8. Welche Metriken, Hardware- und Laufzeitanalysen werden für den Praxisteil erwartet?

Arbeitsstand

Dies ist ein Planungsvorschlag, kein endgültiges Studiendesign. Der Fokus liegt auf TabPFN; andere Tabular Foundation Models dienen nur als Kontext oder Vergleich. Umfang und Formalisierung der Literaturrecherche werden abgestimmt; die Quellenauswahl ist in jedem Fall transparent zu beschreiben.