Vorläufige Gliederung der Bachelorarbeit

Arbeitstitel

Robustheit von TabPFN-3.5 gegenüber irrelevanten Merkmalen: Eine kontrollierte Untersuchung im Vergleich zu LightGBM

Forschungsfragen

Übergeordnete Forschungsfrage: Wie robust ist TabPFN-3.5 gegenüber schrittweise hinzugefügten unabhängigen, irrelevanten Merkmalen im Vergleich zu LightGBM, und wie ist dieses Ergebnis anhand der methodischen Entwicklung und bisherigen Evaluationen von TabPFN einzuordnen?

FF1 – Literaturteil: Welche relevanten methodischen Änderungen und adressierten Herausforderungen tabellarischer Daten beschreiben ausgewählte TabPFN-Arbeiten, und welche Schlussfolgerungen erlauben ihre Evaluationen?

FF2 – empirischer Teil: Wie verändert sich die Klassifikationsleistung von TabPFN-3.5 und LightGBM bei schrittweiser Zugabe unabhängiger, irrelevanter Merkmale?

Die Versionsentwicklung dient nur der Einordnung von TabPFN-3.5. FF2 bildet den empirischen Schwerpunkt. Aussagen aus dem Vergleich mit LightGBM werden nicht auf alle baumbasierten Verfahren übertragen.

Vorläufige Gliederung

1. **Einleitung**
   (a) Problemstellung und Motivation
   (b) Zielsetzung und Forschungsfragen
   (c) Abgrenzung und Aufbau der Arbeit
2. **Grundlagen**
   (a) Tabellarische Klassifikationsaufgaben und ihre Besonderheiten
   (b) TabPFN als Tabular Foundation Model
   (c) Bayesianische Priors und Prior-Data Fitted Networks
   (d) Baumbasiertes Gradient Boosting und LightGBM
   (e) Irrelevante Merkmale und Robustheit von Klassifikationsmodellen
3. **Stand der Forschung und Literaturanalyse**
   (a) TabPFN: methodische Entwicklung bis Version 3.5
   (b) Auswahl und Einordnung relevanter TabPFN-Evaluationen
   (c) Vergleichende Forschung zu Deep Learning und Baumverfahren auf Tabellendaten

   (d) Bisherige Befunde zu irrelevanten Merkmalen
   (e) Forschungsbedarf und Herleitung des Experiments
4. **Methodik**
   (a) Forschungsdesign und Versuchsbedingungen
   (b) Datensätze und Auswahlkriterien
   (c) Erzeugung und stufenweise Zugabe irrelevanter Merkmale
   (d) Modelle, Konfigurationen und Vorverarbeitung
   (e) Datenaufteilungen und Wiederholungen
   (f) Metriken und Auswertungsverfahren
5. **Ergebnisse**
   (a) Datensätze und technische Umsetzung
   (b) Ergebnisse ohne zusätzliche irrelevante Merkmale
   (c) Veränderung der Leistung bei zunehmender Zahl irrelevanter Merkmale
   (d) Vergleich der Ergebnisse zwischen Modellen und Datensätzen
6. **Diskussion**
   (a) Beantwortung der Forschungsfragen
   (b) Einordnung in die Literatur
   (c) Aussagekraft, Grenzen und Übertragbarkeit
   (d) Praktische Bedeutung und weiterer Forschungsbedarf
7. **Fazit**

Roter Faden

Tabellarische Daten stellen besondere Anforderungen an Lernverfahren $\longrightarrow$ TabPFN adressiert diese Aufgaben durch einen auf synthetischen Datensätzen trainierten Prior-Data-Fitted-Ansatz $\longrightarrow$ bestehende Arbeiten untersuchen die Leistungsfähigkeit und teilweise die Empfindlichkeit gegenüber irrelevanten Merkmalen $\longrightarrow$ TabPFN-3.5 erweitert laut technischem Bericht den Umgang mit größeren Feature-Zahlen, was jedoch nicht automatisch Robustheit gegenüber gezielt hinzugefügten Störmerkmalen belegt $\longrightarrow$ die Arbeit untersucht diesen Effekt kontrolliert für TabPFN-3.5 und LightGBM.